

同步辐射纳米 CT 图像超分辨率重建及其应用研究

彭 真¹ 汪 澳² 汪 俊³ 陶 芬³ 张 玲³ 杜国浩³ 邓 彪³

1(上海大学 上海 200444)

2(上海理工大学 上海 200093)

3(中国科学院上海高等研究院 上海光源中心 上海 201204)

摘要 同步辐射纳米 CT (Nano-Computed Tomography) 技术因其能够在纳米尺度上提供高分辨率三维结构信息,在材料科学、能源、地质学等多个学科领域发挥着重要作用。然而,环境干扰、设备精度限制及光源强度波动等因素导致纳米 CT 图像信噪比降低、模糊和细节丢失,影响定量分析的准确性。针对这一挑战,本研究在缺少纳米 CT 数据集的情况下,提出了一种基于 Transformer 的图像超分辨率 (Super-resolution, SR) 网络,专门用于提高纳米 CT 图像的质量,还探究其对裂纹分割等后续分析任务的优化效果。该网络采用 U 型对称结构,融合了双卷积前馈网络和分组式多尺度窗口自注意力机制,以实现高效的纳米 CT 图像超分辨率重建。实验结果表明,该网络在计算效率和多个评价指标上均优于 SwinIR 和 Real-ESRGAN 模型。在裂纹分割任务中,经该网络处理后的图像裂纹分割准确率达到 99.3%,召回率提升了 24.5%,验证了图像超分辨率重建技术在裂纹分割预处理中的有效性。

关键词 纳米 CT, 超分辨率, 裂纹分割, 同步辐射, 注意力机制

中图分类号 TP391, TL99

DOI: 10.3724/j.0253-3219.2026.hjs.49.250034

CSTR: 32193.14.hjs.CN31-1342/TL.2026.49.250034

Super-resolution reconstruction of synchrotron radiation nano-CT images and its applications

PENG Zhen¹ WANG Ao² WANG Jun³ TAO Fen³ ZHANG Ling³ DU Guohao³ DENG Biao³

1(Shanghai University, Shanghai 200444, China)

2(University of Shanghai for Science and Technology, Shanghai 200093, China)

3(Shanghai Synchrotron Radiation Facility, Shanghai Advanced Research Institute, Chinese Academy of Sciences, Shanghai 201204, China)

Abstract [Background] Synchrotron radiation nano-computed tomography (nano-CT) is widely applied in materials science, energy research, and geology due to its capability to provide high-resolution three-dimensional structural information at the nanoscale. However, environmental interference, equipment limitations, and light source fluctuations often degrade image quality, leading to reduced signal-to-noise ratio, blurring, and loss of critical details, which severely impact quantitative analysis and segmentation accuracy for microstructures such as cracks and pores. While existing super-resolution (SR) techniques for natural images have significant advantages, their adaptation to

国家重点研发计划(No.2021YFA1600700, No.2021YFA1601001)、国家自然科学基金(No.12275343)资助

第一作者: 彭真, 男, 2000 年出生, 2022 年毕业于德州学院, 现为硕士研究生, 研究领域为 CT 图像处理

通信作者: 邓彪, E-mail: dengb@sari.ac.cn

收稿日期: 2025-01-21, 修回日期: 2025-03-19

Supported by Development Program for Basic Research of China (No. 2021YFA1600700, No. 2021YFA1601001), National Natural Science Foundation of China (No.12275343)

First author: PENG Zhen, male, born in 2000, graduated from Dezhou University in 2022, master student, focusing on CT image processing

Corresponding author: DENG Biao, E-mail: dengb@sari.ac.cn

Received date: 2025-01-21, revised date: 2025-03-19

nano-CT remains challenged by dataset scarcity and stringent reconstruction accuracy requirements. **[Purpose]** This study aims to develop a dedicated super-resolution reconstruction network for synchrotron radiation nano-CT images to enhance the clarity and detail restoration of low-quality CT images and investigate its efficacy in optimizing downstream tasks such as crack segmentation. **[Methods]** Firstly, a Transformer-based U-shaped symmetric network for SR (UTSR) was proposed, integrating a Double Convolutional Feedforward Network (DCFFN) and a Grouped Multi-scale Window Self-Attention (GMSA) mechanism to achieve efficient reconstruction through multi-level feature extraction and hierarchical processing. Then, a transfer learning strategy was adopted, leveraging natural image datasets for pre-training and fine-tuning the model with nano-CT data from the Shanghai Synchrotron Radiation Facility (SSRF) to address dataset scarcity. Finally, a Sobel edge loss function was introduced to prioritize texture preservation, and a two-stage training framework (general image pre-training and nano-CT fine-tuning) was implemented to optimize model performances in terms of Natural Image Quality Evaluator (NIQE), Learned Perceptual Image Patch Similarity (LPIPS), Deep Image Structure and Texture Similarity (DISTS), Peak Signal-to-Noise Ratio (PSNR) and Structural Similarity Index Measure (SSIM). **[Results]** Comparison results show that UTSR demonstrates superior performance on both simulated and nano-CT datasets: it achieves lower NIQE (9.38) and LPIPS (0.312) scores compared to SwinIR and Real-ESRGAN, alongside reduced computational complexity (45.72G FLOPs). When applied to crack segmentation, UTSR-processed images attain an accuracy of 99.3%, with a 24.5% improvement in recall and a 19.1% increase in F1 Score over original images. Ablation experiments confirm the effectiveness of the DCFFN module, where its combination with GMSA further reduces NIQE to 10.99. **[Conclusions]** The UTSR network effectively addresses the challenges of low-quality synchrotron radiation nano-CT images and scarce datasets through its innovative architecture and transfer learning strategy, providing a robust preprocessing solution for microstructural analysis, hence expands the application of deep learning-based super-resolution in scientific imaging, offering substantial academic and engineering value.

Key words Nano-CT, Super-resolution, Crack segmentation, Synchrotron, Attention mechanism

同步辐射纳米CT (Nano-Computed Tomography) 成像是一种基于同步辐射光源的先进X射线成像技术,能够在纳米尺度上提供高分辨率的三维结构信息^[1-2]。与传统CT成像相比,同步辐射纳米CT能对样品的结构进行高精度成像,在材料科学、生命科学和地质资源等领域的微观研究中具有重要应用^[3-5]。尽管同步辐射纳米CT技术在成像分辨率方面已取得显著突破,但其图像质量仍受多种因素影响,包括设备精度限制、同步辐射光源强度波动、微小机械振动等。这些不利因素会导致纳米CT成像模糊、信噪比低、细节丢失等问题,尤其是在分析微小裂纹、复杂孔隙等结构时,低质量的CT图像难以精确地分割裂纹,影响后续分析的准确性^[6]。为提升CT图像的质量和微小裂纹的分割精度,迫切需要发展一种有效的纳米CT图像增强方法。

图像超分辨率 (Super-Resolution, SR) 技术因其显著的图像增强效果逐渐受到关注。该技术可以提升图片分辨率、细化图像边缘、去除模糊,从而提升图像的清晰度和细节。自2014年Dong等^[7]首次将卷积神经网络引入图像SR领域以来,基于深度学习的SR技术取得了显著进展。其中,VDSR (Very Deep Super-Resolution)^[8]和EDSR (Enhanced Deep

Super-Resolution)^[9]通过引入残差结构有效缓解了深层网络的梯度消失问题;DRCN (Deeply-Recursive Convolutional Network)^[10]和DRRN (Deep Recursive Residual Network)^[11]利用递归网络提升了特征提取能力;RCAN (Residual Channel Attention Network)^[12]创新性地引入注意力机制增强了关键特征的表达;LapSRN (Laplacian Pyramid Super-Resolution Network)^[13]和DBPN (Deep Back-Projection Networks)^[14]则在上采样策略方面实现了重要突破。近期,基于Transformer架构的SR网络(如IPT (Image Processing Transformer)^[15]、SwinIR (Swin Transformer for Image Restoration)^[16]、HAT (Hybrid Attention Transformer)^[17]、DAT (Deformable Attention Transformer)^[18]等)不断推动着技术水平的提升。深度学习图像SR技术在CT图像领域也展现出良好的应用前景。2017年Umehara等^[19]把图像SR技术带到了医学CT图像中,效果优于传统的插值算法,充分证明了深度学习图像SR方法可以很好地应用于CT图像的SR重建。接着Zhao等^[20]利用创新的方法制作数据集,使用SRGAN (Super-Resolution Generative Adversarial Network)模型处理岩石CT图像,提升CT图像的清晰度。Ahuja等^[21]

提出了专注于边缘语义的图像SR模型,提升微米CT图像的分辨率。Guan等^[22]提出了一种基于生成对抗网络的模型用于工业CT的伪影校正、噪声抑制和超分辨率重建。近年来,图像SR方法已被用于遥感图像、医学CT图像、红外图像等多个领域中,显示出其在增强图像质量方面的潜力。然而,在自然图像领域,许多研究已经发布了高分辨率数据集,并且在这些场景中图像超分辨率的效果已经非常好,目前关于同步辐射纳米CT图像超分辨率领域的研究相对有限。由于硬件限制和机械精度等问题,获取高分辨率的纳米CT图像非常困难,这进一步限制了监督学习方法的应用。对于自然的图像超分辨率任务对重建精度的要求相对较低。CT图像,尤其是在医学诊断和工业检测中,对超分辨率重建的图像质量和准确性有着极高的要求。如何在这些应用中平衡图像的视觉质量和重建的准确性,成为一个关键的挑战。

针对上述问题,本研究采用迁移学习的方法来克服缺乏纳米CT数据集这一限制,利用大规模自然图像数据集预训练模型,提取其通用特征,同时使用基于上海光源纳米三维成像线站采集的纳米CT数据对模型进行微调,不仅缓解了数据稀缺的问题,还提升了模型性能。本文还提出了一种适用于纳米CT图像的SR网络UTSR(U-Net Transformer Super-Resolution)。并且将图像SR技术应用于同步辐射纳米CT的裂纹分割研究,从图像预处理的角度提升裂纹分割的精度和稳定性。本研究对该方法进行了验证,实验结果表明,该模型在多个评估指标上均优于传统模型,在处理模糊CT图像方面展现了显著优势,有效提高裂纹分割的准确性。

1 图像超分辨网络

1.1 网络整体结构

本研究提出的基于Transformer的图像SR网络结构,如图1所示。该网络采用U型对称结构,旨在高效执行图像超分辨率重建的恢复任务。模型由多个Transformer Block组成,通过多级别的特征提取机制和分层的处理方式实现图像重建,每个Transformer Block由两个核心模块构成:双卷积前馈网络(Double Convolutional Feed-Forward Network, DCFN)和分组式多尺度窗口自注意力机制(Grouped Multi-Scale Window Self-Attention, GMSA)。图像SR网络的工作流程如下:首先,给定的低分辨率图像 I_{LR} ,其尺寸为 $H \times W$,通道数为 C_{IN} ,通过卷积层进行初步处理得到浅层特征 I_0 ,其尺寸

仍为 $H \times W$,但通道数变为 C ,随后,这些浅层特征通过U型编码器—解码器结构进行处理,其中,多级编码器通过逐级下采样使特征尺寸依次减小,同时通道数逐级增加,最终获得尺寸为 $H/8 \times W/8 \times 8C$ 特征,该特征再通过解码器,逐级恢复出高分辨率图像,对于特征下采样和上采样,分别采用pixel-unshuffle和pixel-shuffle算法^[23]。同时为了减少特征损失,编码器通过跳过连接与解码器连接。最终重建后的图片分辨率是原始图像4倍。

1.2 双卷积前馈网络

在标准Transformer模型中,前馈神经网络(Feed-Forward Network, FFN)模块位于每个Transformer层的自注意力机制之后。这种结构允许FFN模块在保持输入输出维度一致的同时,引入更多的非线性变换和特征提取能力,从而增强模型的表达能力。本文提出一种新颖的特征融合模块:双卷积前馈网络,其主要结构如图2(a)所示。该模块通过双路并行处理和特征重组的方式,实现对输入特征的高效增强。首先,输入特征通过一个全连接层(Fully Connected Layer, FC)进行初始变换,随后分为两条并行的处理路径,上分支采用深度可分离卷积加标准卷积的串联结构。深度可分离卷积可以高效提取空间特征,同时显著减少计算开销。接下来的普通卷积进一步整合通道间的信息,提升特征表达能力。下分支同样使用深度可分离卷积提取空间信息,与上路保持一致。但在此基础上,引入激活函数GELU(Gaussian Error Linear Unit),增强模型对复杂特征的建模能力。最后两条路径输出的内容相加融合。其过程定义如式(1):

$$f_{DCFFN} = f_{FC} \left(f_{GELU} \left(f_{DConv} \left(f_{FC}(X) \right) \right) + f_{Conv} \left(f_{DConv} \left(f_{FC}(X) \right) \right) \right) \quad (1)$$

式中: f_{FC} 表示全连接层; f_{DConv} 表示深度卷积; f_{Conv} 表示普通卷积; f_{GELU} 表示非线性激活层。总的来说,DCFFN相比FFN网络能同时学习到不同层次的特征表示,增强了特征提取的多样性,且使模型更加关注图像的局部细节。

1.3 分组式多尺度窗口自注意力

分组式多尺度窗口自注意力模块(GMSA)本文沿用了ELAN模型^[24]中的设置,其结构如图2(b)所示。一个分组式多尺度窗口自注意力模块包含多个窗口自注意力(Window Self-Attention, WSA)模块,可以通过设置不同WSA模块的窗口大小的比例来灵活控制计算成本。对于给定的一个大小为 $H \times W \times C$ 的特征 X_{IN} 输入到WSA模块中,首先会将其




图1 图像超分辨率模型 UTSR 的网络结构示意图
Fig.1 Network architecture diagram of UTSR model for image super-resolution




图2 Transformer Block 内部组成结构示意图
(a) 双卷积前馈网络结构, (b) 分组式多尺度窗口自注意力结构

Fig.2 Diagram of internal structure of the Transformer Block
(a) Double convolutional feed-forward network structure,
(b) Grouped multi-scale window self-attention

分成 HW/S^2 个不重叠的窗口 X , 其中 S 是每个窗口的边长。之后通过三个 1×1 卷积 L_Q, L_K, L_V 来得到 Q, K 和 V :

$$Q, K, V = L_Q(X), L_K(X), L_V(X) \quad (2)$$

之后通过得到的 Q, K 和 V 计算每个窗口的自注意力, 其窗口自注意力公式为:

$$\text{Attention}(Q, K, V) = \text{Soft max} \left(\frac{QK^T}{\sqrt{d}} \right) V \quad (3)$$

将每个窗口自注意力合并得到最终结果。多个并行运行的 WSA 模块共同构成了 GMSA 结构。由于分组模式的作用 GMSA 能够在不同的细粒度下处理输入数据, 从而增强捕获多个空间尺度的复杂依赖关系的能力。

1.4 损失函数

自然图像训练时通常使用 L1 损失优化模型, 这种损失函数会平等的对待图像中的所有区域, 缺乏

对图像边缘和纹理的关注。由于纳米 CT 对细节的准确度要求高, 因此为了使模型关注细节部分, 提升准确度, 本研究提出了 sobel 损失函数, 通过边缘检测的方式, 提取出图片中的边缘信息计算损失, 提升模型对纹理的关注度。本文使用了两种损失函数, 分别为 L_1 损失、 L_{sobel} 感知损失, 损失的总公式如下:

$$L_{\text{sobel}} = \|G_{x\text{HR}} - G_{x\text{LR}}\| + \|G_{y\text{HR}} - G_{y\text{LR}}\| \quad (4)$$

$$L = L_1 + \eta L_{\text{sobel}} \quad (5)$$

式中: $G_{x\text{HR}}$ 表示对高分辨率图像 X 方向求梯度; $G_{x\text{LR}}$ 表示对低分辨率图像 X 方向求梯度; 同理 $G_{y\text{HR}}$ 和 $G_{y\text{LR}}$ 表示对图像 Y 方向求梯度; L 表示总损失; η 表示对应的权重系数。

2 实验结果与分析

2.1 数据集制作

目前, 尚未有公开的纳米 CT 数据集, 且由于物理限制高质量的纳米 CT 图像难以获取。在纳米 CT 数据集稀缺的情况下, 本研究的实验数据集分为两部分: 普通图像超分辨率数据集和同步辐射纳米 CT 数据集。普通图像数据集由 DIV2K^[25]、Flickr2K^[26] 和 OutdoorSceneTraining^[27] 构成, 用于模型的预训练, 提取其通用特征, 减少对大量纳米 CT 数据的需求。另一部分为纳米 CT 图像组成的数据集。同步辐射纳米 CT 数据的采集在上海同步辐射光源 (BL18B) 纳米三维成像光束线站完成, 采用硬 X 射线全场透射纳米显微成像系统^[28-29]。实验样品选用黄膨润土和电池中的高镍三元正极材料 $\text{LiNi}_{0.8}\text{Co}_{0.1}\text{Mn}_{0.1}\text{O}_2$ (NCM811), 图 3(a)、(d) 为显微镜下样品的照片。对于黄膨润土和 NCM811 样品, 入射 X 射线

能量分别设定为 7 keV 和 8.4 keV, NCM811 样品的曝光时间为 0.8 s, 单像素尺寸为 46 nm, 投影图采集尺寸为 480×308; 黄膨润土的曝光时间为 1.5 s, 单像素尺寸为 38 nm, 投影图采集尺寸为 552×392。每种

样品均采集 361 张均匀分布的投影图, 使用 AduRecon 软件进行三维重建^[30], 获得样品的切片图像序列(图 3(c、f))。其中精选 3 000 张高质量图像构建训练集。




图3 实验中采集到数据图片 (a) NCM811 样品图片, (b) NCM811 同步辐射投影图像, (c) NCM811 的切片图像, (d) 黄膨润土样品照片, (e) 黄膨润土同步辐射投影图像, (f) 黄膨润土的切片图像

Fig.3 Data images collected in the experiments (a) Image of the NCM811 sample, (b) NCM811 synchrotron radiation projection image, (c) Slice image of NCM811, (d) Image of the Huang peng bentonite sample, (e) Huang peng bentonite synchrotron radiation projection image, (f) Slice image of Huang peng bentonite

为了准确模拟图像退化, 所以本研究采用与 BSRGAN (Blind Super-Resolution Generative Adversarial Network)^[31] 相同的退化模型, 该研究引入了一个更为复杂且实用的退化模型, 旨在更准确地模拟真实世界中图像退化的多样性。低质量图像的合成流程如图 4 所示。该流程首先对原始图像进行下采样处理, 随后引入随机噪声和模糊效果, 以生成更低质量的图像。本文对两种数据集都进行退化处理合成低质量的图像, 进行模型训练。在模型训练中, 本文将 3 000 张高质量 CT 图像划分为训练集、验证集和测试集, 具体分配如下: 训练集 2 600 张, 验证集 300 张, 测试集 100 张。为了丰富训练样本的多样性, 随机旋转 90°、180° 或 270°, 以及随机水平翻转的方式进行数据增强, 训练集扩增了 4 倍, 总共 10 400 张。

2.2 实验设置与模型训练

本模型的训练分为两个阶段: 第一阶段为普通




图4 低质量图像合成流程图
Fig.4 Flowchart of low-quality image synthesis

图像训练的过程; 第二阶段是纳米 CT 图像训练过程。对于模型的细节网络中 Transformer Block 数量的从 1 到 4 依次为 [12, 2, 2, 8], GMSA 模块中窗口大小为 4×4、8×8 和 16×16。其中 $\eta = 0.2$, 该值通过实验调整得到, 若该值过大会致模型过于关注边缘的细节, 从而忽略图像的全局结构和内容, 降低图像质量。第一阶段模型使用 Adam 优化器, 其中 $\beta_1 = 0.9, \beta_2 = 0.99$ 。模型迭代 3×10^5 次, 初始学习率为 1×10^{-4} , 在第 $\{200 \times 10^3, 250 \times 10^3, 450 \times 10^3, 475 \times 10^3\}$ 次迭代时减半。训练用时为 63 h 37 min 21 s。第二阶段在第一阶段基础上参数不变, 使用纳米 CT 数据集进行训练, 只有初始学习率改为 1×10^{-5} , 模型迭代 10×10^3 次。训练用时为 3 h 25 min 13 s。本次实验的计算机硬件环境: 中央处理器 (Central Processing Unit, CPU) 型号 Intel Xeon W-2245, 内存 64 GB, 显卡为 NVIDIA RTX 3090, 24 GB 显存。编程语言为 Python 3.9。详细实验环境及模型参数如表 1 所示。

其中训练过程的损失函数收敛曲线如图 5 所示, 随着迭代次数的增加, 模型的损失函数值稳定下降, $0 \sim 10 \times 10^3$ 次损失值迅速降低, 之后的损失值稳定下降, 直到模型训练结束。

2.3 模拟图像超分辨率结果分析

对于图像超分辨率任务本文选择定性分析和定量分析相结合, 评估图像 SR 模型。由于缺少真实高

表1 模型参数及实验环境
Table 1 Model parameters and experimental environment

	参数 Parameter	参数值 Parameter value
模型 Model	Transformer Block 数量	[12, 2, 2, 8]
	Transformer Block parameter	
	GMSA 模块窗口大小	4×4, 8×8, 16×16
	GMSA module window size	
	优化器 Optimizer	Adam
	初始学习率 Initial learning rate	1×10^{-4}
	学习率调整 Learning rate scheduling	$\{200 \times 10^3, 250 \times 10^3, 450 \times 10^3, 475 \times 10^3\}$
实验环境 Experimental environment	CPU	Intel Xeon W-2245
	内存 RAM	64 GB
	GPU	NVIDIA RTX 3090, 24 GB
	编程语言 Programming language	Python 3.9




图5 损失函数值随迭代次数变化
Fig.5 Loss function variation chart with iterations

质量的CT图像,本文选用盲图像超分辨率模型的评价指标定量评估模型重建出的图片质量。这些评价指标包括自然图像质量评估器(Natural Image Quality Evaluator, NIQE)^[32]、学习感知图像块相似度(Learned Perceptual Image Patch Similarity, LPIPS)^[33]、深度图像结构与纹理相似性(Deep Image Structure and Texture Similarity, DISTS)^[34]。NIQE是一种基于自然场景统计特征的无参考图像质量评估指标。其使用高斯混合模型来建立自然图像特征的概率分布,并用该分布来评估输入图像的质量分数。分数越低表示图像质量越高。LPIPS使用预训练的深度网络(如VGG、AlexNet)来提取图像特征,然后计算这些特征之间的距离,以评估图像之间的感知相似度,分数越低表示两张图像越相似。DISTS是评价两张图片相似性的指标,通过融合结构和纹理相似性来计算图像之间的差异,分数越低证明两张图片之间的差异越少。

UTSR模型的评估,本文选择了代表性的自然图像SR网络Real-ESRGAN和SwinIR模型做对比,所有模型都是采用相同训练次数和相同的数据集进行训练。由于纳米CT图像质量欠佳,模型准确性评估面临挑战。因此,本研究采用高质量微米CT数据

集进行测试,并使用本文提出的低质量图像生成方法构建微米CT低质量测试集,以验证模型的性能和可行性。为客观评价模型的准确度及性能,本研究采用峰值信噪比(Peak Signal-to-Noise Ratio, PSNR)和结构相似性指数(Structural Similarity Index Measure, SSIM)作为定量分析指标。表2为图像SR算法的定量比较,结果表明本研究提出的UTSR模型在两项指标上均优于其他模型。与传统Bicubic算法相比,UTSR模型在PSNR上提升了2.85 dB,在SSIM上提升了0.081。图6展示了各模型重建图像的质量。结果表明,基于深度学习的超分辨率方法在图像重建方面显著优于传统插值方法,特别是UTSR模型在边缘锐化和细节清晰度方面表现最佳。观察图像可知,Bicubic算法重建的图像存在明显模糊和噪声。Real-ESRGAN算法在噪声抑制方面表现均衡,但在去模糊方面存在不足。相比之下,UTSR模型能够保留更多细节信息,且与真实图像更为接近。

表2 模拟图像SR算法进行定量比较
Table 2 Quantitative comparison of image super-resolution algorithms using simulated images

指标 Index	Bicubic	Real-ESRGAN	SwinIR	UTSR
PSNR	31.70	33.58	33.94	34.55
SSIM	0.853	0.908	0.912	0.934

为验证本研究模型在纳米CT图像边缘及特征分割提取方面的有效性,本文还采用了模拟的低质量纳米CT图像进行分析。此外,引入衬噪比(Contrast-to-noise ratio, CNR)和剖面图,以进一步评估模型性能。图7(a)展示了UTSR处理前后效果的对比。为保证图像尺寸一致性,便于后续对CNR的计算,本文采用Bicubic插值算法对图像进行上采样。如图7(a)所示,UTSR模型处理后的图像裂纹边缘更加清晰,噪声水平显著降低,有利于裂纹的提




图6 模拟图像SR方法进行定性比较

Fig.6 Qualitative comparison of super-resolution methods using simulated images

取。图7(b)展示了图像的CNR分析结果。柱状图显示,UTSR处理后的图像CNR值(绿色柱状)显著高于未经处理的图像,这表明UTSR模型能够有效提升图像的衬噪比,从而更有利于特征提取。此外,

图7(c)的对比结果进一步证实,UTSR模型处理后的图像对比度更高。综上所述,实验结果充分验证了本文所提出的UTSR模型的有效性。




图7 模拟低质量纳米CT图像验证UTSR(彩图见网络版) (a) UTSR处理效果对比图,(b) CNR对比图,(c) 剖面图分析

Fig.7 Validation of UTSR using simulated low-quality nano-CT images (color online)

(a) Comparison of UTSR processing effects, (b) CNR comparison chart, (c) Profile analysis

2.4 纳米CT图像超分辨率结果分析

为了准确评估模型在实际图像处理中的效果,本研究选择了多张真实情况下的低质量纳米CT图像,以验证各种算法的性能。表3展示了不同算法

之间的定量比较。通过对比NIQE指标,可以看出模型UTSR表现最佳,其值比Real-ESRAGN模型低1.29,同时UTSR模型的LPIPS值也最低。这表明该模型在实现高质量图像重建的同时,在结构保持方

面也表现突出。仅在 DISTS 指标上,UTSR 模型稍微落后于 Real-ESRGAN 模型。

图 8 展示的是各种算法处理低质量图片后的效果图。图 8(a)中,从最左侧可以看到输入图片,很明显这些图片细节不清晰,存在着大量模糊,且边缘不够清晰,对于后续的研究存在影响。右侧是处理后的图片,可以观察到三个模型都去除了图片中的模糊,显露出清晰的纹理和边缘。从图 8(b)可以看出三种模型均对图像质量做了提升,但是细节上存在着一些差异。对于 SwinIR 模型重建的图片锐化过度,缺少细节。Real-ESRGAN 模型虽然重建出很多

清晰纹理,但边缘部分存在着较多模糊,关注范围只在中心部分。而本文提出的 UTSR 模型有丰富的细节且边缘模糊更少。

表 3 图像 SR 算法进行定量比较
Table 3 Quantitative comparison of image super-resolution algorithms

方法 Methods	FLOPs(G)	NIQE	LPIPS	DISTS
SwinIR	52.96	12.38	0.309	0.230 4
Real_ESRGAN	70.74	12.28	0.302	0.227 0
UTSR	45.72	10.99	0.295	0.232 0




图 8 在 SR 任务上图像 SR 方法进行定性比较 (a) 土壤纳米 CT 图像, (b) NCM 电池颗粒的纳米 CT 图像

Fig.8 Qualitative comparison of SR methods on SR tasks

(a) Nanoscale CT images of soil, (b) Nanoscale CT images of NCM battery particles

2.5 裂纹分割的结果分析

为探究图像超分辨率算法的实际应用,本文探究了图像超分辨率对于裂纹分割精度的影响。本文使用图像分割领域广泛使用的评价指标进行定量分析,包括 Accuracy、Precision、Recall、F1Sorce^[35]。Accuracy 表示模型正确预测的像素占总像素的比例。

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \quad (6)$$

Precision 表示模型预测为裂纹的像素中有多少

是真正的裂纹。

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (7)$$

Recall 表示实际为裂纹的像素中有多少被模型正确识别为裂纹。

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (8)$$

F1Sorce 是 Precision 和 Recall 的调和平均数, F1Sorce 越高,说明模型的性能越好。F1Sorce 公式为:

$$F1Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (9)$$

式中：TP 为正确预测的裂纹像素数；FP 为非裂纹预测为裂纹的像素数；FN 为裂纹预测为非裂纹的像素数；TN 为正确预测的非裂纹像素数。

为验证图像 SR 算法在纳米 CT 图像裂纹中的效果，本研究选择 NCM811 和黄膨润土的 CT 图像作为验证数据。裂纹分割采用基于局部自适应二值化的裂纹分割算法，参照对象则是通过检测算法与人工修正生成的高精度分割结果。基于表 4 的定量分析结果表明，将图像 SR 算法作为预处理步骤能显著提

升裂纹分割的性能指标。特别是本文提出的 UELSR 模型在各项评价指标上均展现出优异性能，在 F1Score 上对比未经预处理的图像提升了 19.1%，并且在 Accuracy 上 UTSR 模型位居首位。此外，本文还验证了图像 SR 算法在孔隙提取的方面的效果，通过表 4 可以看到引入图像 SR 算法后各项指标均略有提升。同样 UTSR 在 Accuracy 上表现突出，F1Score 的指标达到了 82.8%，这充分证明了 UTSR 在微观结构特征分割任务中的有效性，特别是在平衡精确率和召回率方面表现出色。

表 4 多种图像 SR 算法处理后裂纹和孔隙分割的定量比较
Table 4 Quantitative comparison of crack and pore segmentation after processing with various image SR algorithms

方法 Methods	裂纹 Crack				孔隙 Pore			
	Accuracy / %	Precision / %	Recall / %	F1Score / %	Accuracy / %	Precision / %	Recall / %	F1Score / %
Original	98.7	81.7	35.4	49.4	94.4	60.8	87.6	71.8
Bicubic	99.2	95.6	41.2	57.7	96.4	89.7	66.6	76.4
SwinIR	99.3	87.1	57.7	69.4	96.9	84.2	79.3	81.7
Real_ESRGAN	99.2	78.5	57.3	66.3	96.5	85.1	73.5	78.8
UTSR	99.3	80.1	59.9	68.5	97.1	84.2	81.4	82.8

图 9 和图 10 是裂纹和孔隙分割后的结果，从图 9 明显的看到未经图像 SR 处理的图片只提取到少部分裂纹，对于较细微的裂纹检测效果有限。相比经过图像 SR 处理后的图片，可以提取到大部分的裂纹，只有少部分丢失。这印证了图像 SR 在裂纹分割中的优异表现。对比不同 SR 算法的分割结果可以发现，UTSR 模型分割效果更接近于实际情况。这

与表 4 中的数据相互印证。观察图 10 可以看出在孔隙分割任务中，UTSR 模型同样展现出优越性，尽管从整体上看，各处理方式所提取的孔隙近乎相同，但仔细观察可发现其他处理方式所提取的孔隙存在少量缺失现象。通过以上研究可以证明适当的图像 SR 算法对裂纹分割有很大帮助，同时也体现了其在裂纹分割应用中的潜力。




图 9 多种图像 SR 算法处理后裂纹分割的定性比较
Fig.9 Qualitative comparison of crack segmentation after processing with various image SR algorithms

2.6 消融实验

为验证本文提出的 DCFFN 模块的有效性，本文使用 UTSR 模型中的 GMSA 模块测试基准，分别搭配 FFN 和 DCFFN 做消融实验。实验采用相同的训练参数和实验条件。通过挑选的纳米 CT 数据集做

测试。实验结果如表 5 所示，观察表中的数据可以发现当 GMSA 与 DCFFN 结合时，NIQE 得分显著降低至 10.99，LPIPS 得分降至 0.295，DISTS 得分略微上升至 0.238，这些指标的表现明显好于 GMSA 与 FFN 结合的结果。这些结果表明，DCFFN 的引入显




图 10 多种图像SR算法处理后孔隙提取的定性比较

Fig.10 Qualitative comparison of pore extraction after processing with various image SR algorithms

著提升了模型的整体性能,同时证明了DCFFN模块的有效性。

表 5 不同模块的组合对比结果
Table 5 Comparison results of different module combinations

GMSA	FFN	DCFFN	NIQE	LPIPS	DISTS
✓	×	×	12.44	0.338	0.231
✓	✓	×	11.47	0.318	0.250
✓	×	✓	10.99	0.295	0.238

3 结语

本研究在纳米CT数据集有限的情况下,使用迁移学习训练出了一种基于Transformer的图像超分辨率网络UTSR,专注于同步辐射纳米CT图像的高效重建。通过引入双卷积前馈网络和分组式多尺度窗口自注意力机制,使模型更加关注图像中的细节。同时本文使用sobel边缘检测做损失函数,既提升了图像质量又确保了图像的精度问题。UTSR网络在低质量纳米CT图像重建展现了显著优势。在模拟数据集和自制的纳米CT数据集测试结果表明,与现有的SR模型(如SwinIR和Real-ESRGAN)相比,UTSR网络在多项评价指标上均表现优越。具体来说,该模型在NIQE、LPIPS和DISTS等评价指标上均实现了更优的数值,表明其在生成清晰、自然纹理的图像方面具有更好的表现。本文还研究了将图像超分辨率算法作为预处理对裂纹分割的影响。通过文中的实验数据可以看出将图像SR作为预处理步骤能够显著改善分割性能。UTSR处理后的图像裂纹分割的准确率、精确率和召回率分别达到99.3%、80.1%、59.9%,特别是F1 Score达到68.5%较原始图像提高了19.1%。这些结果验证了图像超分辨率算法在提升图像裂纹分割精度方面的有效性。综上所述,本研究从预处理的角度出发,为解决同步辐射纳

米CT低质量图像在后续分析中的局限性提供了新思路。这一成果不仅拓展了深度学习图像超分辨率技术的应用领域,也为微观结构特征分析提供了技术支持。

作者贡献声明 彭真负责测量实验的设计及数据整理和分析,论文构思和撰写;汪澳、汪俊负责测量实验的设计及数据整理和分析;陶芬、张玲、杜国浩负责实验测量;邓彪负责测量方法的提出及设计、论文审核与编辑写作、最终版本的修订。

参考文献

- 袁清习, 邓彪, 关勇, 等. 同步辐射纳米成像技术的发展与应用[J]. 物理, 2019, 48(4): 205 - 218. DOI: 10.7693/wl20190401.
YUAN Qingxi, DENG Biao, GUAN Yong, *et al.* Novel developments and applications of nanoscale synchrotron radiation microscopy[J]. Physics, 2019, 48(4): 205 - 218. DOI: 10.7693/wl20190401.
- 邢彦军, 高若阳, 张玲, 等. 基于多项式回归与线性插值的全场纳米谱学成像背景序列预测[J]. 核技术, 2024, 47(3): 030102. DOI: 10.11889/j.0253-3219.2024.hjs.47.030102.
XING Yanjun, GAO Ruoyang, ZHANG Ling, *et al.* Background sequence prediction for TXM-XANES based on polynomial regression and linear interpolation[J]. Nuclear Techniques, 2024, 47(3): 030102. DOI: 10.11889/j.0253-3219.2024.hjs.47.030102.
- 谢红兰, 邓彪, 杜国浩, 等. 上海光源X射线成像及其在材料科学上的应用研究进展[J]. 失效分析与预防, 2021, 16(1): 46 - 59+69. DOI: 10.3969/j.issn.1673-6214.2021.01.005.
XIE Honglan, DENG Biao, DU Guohao, *et al.* Development of X-ray imaging methodology and its

- applications on material science at Shanghai Synchrotron Radiation Facility[J]. *Failure Analysis and Prevention*, 2021, **16**(1): 46 – 59+69. DOI: 10.3969/j.issn.1673-6214.2021.01.005.
- 4 仇正杰, 李可, 谢红兰, 等. 20 Hz 高时空分辨 X 射线单色光动态显微 CT 研究[J]. *核技术*, 2023, **46**(7): 070101. DOI: 10.11889/j.0253-3219.2023.hjs.46.070101.
QIU Zhengjie, LI Ke, XIE Honglan, *et al.* Study of 20 Hz high spatial-temporal resolution monochromatic X-ray dynamic micro-CT[J]. *Nuclear Techniques*, 2023, **46**(7): 070101. DOI: 10.11889/j.0253-3219.2023.hjs.46.070101.
- 5 许明伟, 薛艳玲, 陈荣昌, 等. 基于相位衬度成像的 X 射线生物特征识别仪[J]. *核技术*, 2021, **44**(8): 080202. DOI: 10.11889/j.0253-3219.2021.hjs.44.080202.
XU Mingwei, XUE Yanling, CHEN Rongchang, *et al.* A biometrics recognition instrument using X-ray phase contrast imaging for biosafety inspection[J]. *Nuclear Techniques*, 2021, **44**(8): 080202. DOI: 10.11889/j.0253-3219.2021.hjs.44.080202.
- 6 苏博, 陶芬, 李可, 等. 同步辐射纳米 CT 图像配准方法研究[J]. *物理学报*, 2021, **70**(16): 53 – 67. DOI: 10.7498/aps.70.20210156.
SU Bo, TAO Fen, LI Ke, *et al.* Image alignment for synchrotron radiation based X-ray nano-CT[J]. *Acta Physica Sinica*, 2021, **70**(16): 53 – 67. DOI: 10.7498/aps.70.20210156.
- 7 Dong C, Loy C C, He K M, *et al.* Learning a deep convolutional network for image super-resolution[C]. *Computer Vision – ECCV 2014*. Cham: Springer International Publishing, 2014: 184 – 199. DOI: 10.1007/978-3-319-10593-2_13.
- 8 Kim J, Lee J K, Lee K M. Accurate image super-resolution using very deep convolutional networks[C]. Las Vegas, NV, USA: 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016: 1646 – 1654. DOI: 10.1109/CVPR.2016.182.
- 9 Lim B, Son S, Kim H, *et al.* Enhanced deep residual networks for single image super-resolution[C]. Honolulu, HI, USA: 2017 IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), 2017: 1132 – 1140. DOI: 10.1109/CVPRW.2017.151.
- 10 Kim J, Lee J K, Lee K M. Deeply-recursive convolutional network for image super-resolution[C]. Las Vegas, NV, USA: 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), June 27-30, 2016. IEEE, 2016: 1637 – 1645. DOI: 10.1109/CVPR.2016.181.
- 11 Tai Y, Yang J, Liu X M. Image super-resolution *via* deep recursive residual network[C]. Honolulu, HI, USA: 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017: 2790 – 2798. DOI: 10.1109/CVPR.2017.298.
- 12 Zhang Y L, Li K P, Li K, *et al.* Image super-resolution using very deep residual channel attention networks[C]. Cham: Springer International Publishing: *Computer Vision – ECCV*, 2018: 294 – 310. DOI: 10.1007/978-3-030-01234-2_18.
- 13 Lai W S, Huang J B, Ahuja N, *et al.* Deep Laplacian pyramid networks for fast and accurate super-resolution [C]. Honolulu, HI, USA: 2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017: 5835 – 5843. DOI: 10.1109/CVPR.2017.618.
- 14 Haris M, Shakhnarovich G, Ukita N. Deep back-projection networks for super-resolution[C]. Salt Lake City, UT, USA: 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, June 18-23, 2018: 1664 – 1673. DOI: 10.1109/CVPR.2018.00179.
- 15 Chen H T, Wang Y H, Guo T Y, *et al.* Pre-trained image processing transformer[C]. Nashville, TN, USA: 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2021: 12294 – 12305. DOI: 10.1109/cvpr46437.2021.01212.
- 16 Liang J Y, Cao J Z, Sun G L, *et al.* SwinIR: image restoration using swin transformer[C]. Montreal, BC, Canada: 2021 IEEE/CVF International Conference on Computer Vision Workshops (ICCVW), 2021: 1833 – 1844. DOI: 10.1109/ICCVW54120.2021.00210.
- 17 Chen X Y, Wang X T, Zhou J T, *et al.* Activating more pixels in image super-resolution transformer[C]. Vancouver, BC, Canada: 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2023: 22367 – 22377. DOI: 10.1109/CVPR52729.2023.02142.
- 18 Chen Z, Zhang Y L, Gu J J, *et al.* Dual aggregation transformer for image super-resolution[C]. Paris, France: 2023 IEEE/CVF International Conference on Computer Vision (ICCV), 2023: 12278 – 12287. DOI: 10.1109/ICCV51070.2023.01131.
- 19 Umehara K, Ota J, Ishida T. Application of super-resolution convolutional neural network for enhancing image resolution in chest CT[J]. *Journal of Digital Imaging*, 2018, **31**(4): 441 – 450. DOI: 10.1007/s10278-017-0033-z.
- 20 Zhao B C, Saxena N, Hofmann R, *et al.* Enhancing

- resolution of micro-CT images of reservoir rocks using super resolution[J]. Computers & Geosciences, 2023, **170**: 105265. DOI: 10.1016/j.cageo.2022.105265.
- 21 Ahuja V R, Gupta U, Rapole S R, *et al.* Siamese-SR: a Siamese super-resolution model for boosting resolution of digital rock images for improved petrophysical property estimation[J]. IEEE Transactions on Image Processing, 2022, **31**: 3479 – 3493. DOI: 10.1109/TIP.2022.3172211.
 - 22 Guan Y, Zhang S, Wang H W, *et al.* Multifunctional GAN-based optimization for X-ray tomography under different conditions[J]. Optics Express, 2024, **32**(23): 40767 – 40782. DOI: 10.1364/OE.527366.
 - 23 Shi W Z, Caballero J, Huszár F, *et al.* Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network[C]. Las Vegas, NV, USA: 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016: 1874 – 1883. DOI: 10.1109/CVPR.2016.207.
 - 24 Zhang X D, Zeng H, Guo S, *et al.* Efficient long-range attention network for Image super-resolution[C]. Cham: Springer Nature Switzerland: Computer Vision – ECCV, 2022: 649 – 667. DOI: 10.1007/978-3-031-19790-1_39.
 - 25 Agustsson E, Timofte R. NTIRE 2017 challenge on single image super-resolution: dataset and study[C]. Honolulu, HI, USA: 2017 IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), 2017: 1122 – 1131. DOI: 10.1109/CVPRW.2017.150.
 - 26 Timofte R, Agustsson E, Van Gool L, *et al.* NTIRE 2017 challenge on single image super-resolution: methods and results[C]. Honolulu, HI, USA: Proceedings of the 2017 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW). IEEE, 2017: 1110 – 1121. DOI: 10.1109/CVPRW.2017.149.
 - 27 Wang X T, Yu K, Dong C, *et al.* Recovering realistic texture in image super-resolution by deep spatial feature transform[C]. Salt Lake City, UT, USA: 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018: 606 – 615. DOI: 10.1109/CVPR.2018.00070.
 - 28 Zhang L, Tao F, Wang J, *et al.* The 3D nanoimaging beamline at SSRF[J]. Nuclear Science and Techniques, 2023, **34**(12): 201. DOI: 10.1007/s41365-023-01347-4.
 - 29 Tao F, Wang J, Du G H, *et al.* Full-field hard X-ray nanotomography at SSRF[J]. Journal of Synchrotron Radiation, 2023, **30**(Pt 4): 815 – 821. DOI: 10.1107/S1600577523003168.
 - 30 Zhang L, Tao F, Du G H, *et al.* In-house design hard X-ray transmission microscope at SSRF[J]. Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment, 2023, **1057**: 168781. DOI: 10.1016/j.nima.2023.168781.
 - 31 Zhang K, Liang J Y, Van Gool L, *et al.* Designing a practical degradation model for deep blind image super-resolution[C]. Montreal, QC, Canada: 2021 IEEE/CVF International Conference on Computer Vision (ICCV), October 10-17, 2021: 4771 – 4780. DOI: 10.1109/ICCV48922.2021.00475.
 - 32 Mittal A, Soundararajan R, Bovik A C. Making a "completely blind" image quality analyzer[J]. IEEE Signal Processing Letters, 2013, **20**(3): 209 – 212. DOI: 10.1109/LSP.2012.2227726.
 - 33 Zhang R, Isola P, Efros A A, *et al.* The unreasonable effectiveness of deep features as a perceptual metric[C]. Salt Lake City, UT, USA: 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, June 18-23, 2018: 586 – 595. DOI: 10.1109/CVPR.2018.00068.
 - 34 Ding K Y, Ma K D, Wang S Q, *et al.* Image quality assessment: unifying structure and texture similarity[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022, **44**(5): 2567 – 2581. DOI: 10.1109/TPAMI.2020.3045810.
 - 35 Czimmermann T, Ciuti G, Milazzo M, *et al.* Visual-based defect detection and classification approaches for industrial applications-a SURVEY[J]. Sensors, 2020, **20**(5): 1459. DOI: 10.3390/s20051459.